

Resultados del entrenamiento multimodal

Caso cáncer de mama | RTX 3090 | 7 de octubre de 2026

Imágenes DCE y cuatro variables clínicas: edad, volumen tumoral, HR y HER2.

AUC media de folds	AUC OOF agrupada	Cambio frente a clínica
0.7243	0.7246	+0.0175

Valoración del resultado

Se completaron los 20 entrenamientos. El candidato seleccionado obtiene AUC media de folds 0.7243 y AUC OOF agrupada 0.7246, con IC95% descriptivo [0.6914, 0.7560], frente a 0.5945 de la CNN histórica.

Frente al modelo solo clínico, la diferencia de AUC media de folds es +0.0167, con IC95% descriptivo [+0.0044, +0.0285]. En AUC OOF agrupada, el cambio respecto a 0.7071 es +0.0175, con intervalo [+0.0059, +0.0292]. El intervalo descriptivo de la diferencia queda por encima de cero.

Cumple los tres requisitos cuantitativos definidos (AUC media, AUC agrupada y AP sobre prevalencia).

La selección de épocas y de combinación utiliza estas mismas pacientes de validación. La evaluación es interna y adaptativa: puede sobreestimar la mejora y requiere confirmación en pacientes nuevas.

Por indicación del usuario se asume que edad, volumen tumoral, HR y HER2 estarán disponibles en la prueba privada. Es un supuesto de trabajo, no una confirmación externa. El informe conserva el modelo histórico y no realiza evaluación nueva sobre test.

Modelo	AUC media	AUC OOF	AP	Brier
CNN histórica	0.6001	0.5945	0.3774	0.2359
Solo clínica	0.7076	0.7071	0.4977	0.2170
Multimodal elegido	0.7243	0.7246	0.5316	0.2109

Desarrollo: 1097 pacientes, 322 con pCR; prevalencia 0.294. Evaluación por paciente y probabilidades crudas. AP: precisión promedio. Brier menor es favorable.

Protocolo y selección

Se ejecutó la matriz fijada: una configuración, dos pérdidas, dos semillas y cinco folds; 20 runs secuenciales. Presupuesto máximo de 46 épocas, lote 64, cuatro workers, AdamW y parada temprana. El preprocesado y la regresión clínica inicial se ajustan solo con pacientes de aprendizaje de cada fold.

El checkpoint se elige con AUC de paciente del fold de validación, incluyendo la época 0. Esa misma validación selecciona BCE y agregación. Por ello el rendimiento OOF es de desarrollo adaptativo, con posible optimismo de selección.

Seis combinaciones completas

BCE	Agregación	AUC media	AUC OOF	AUC mínima	AP	Elegido
normal	media	0.7242	0.7025	0.7051	0.4895	
normal	máximo	0.7213	0.7031	0.7020	0.4957	
normal	mediana	0.7232	0.7019	0.7042	0.4907	
ponderada	media	0.7240	0.7244	0.7066	0.5318	
ponderada	máximo	0.7235	0.7233	0.6981	0.5309	
ponderada	mediana	0.7243	0.7246	0.7081	0.5316	Sí

Combinación elegida: pool_dropout_wd_clinical_weighted_median


La regla fijada prioriza AUC media de folds, después AUC OOF y después menor Brier. La ventaja de AUC media frente a normal/media es solo 0,00012; no demuestra una superioridad firme de esta pérdida o agregación.

Resultados por fold


Fold	N	CNN	Clínico	Multimodal	Delta clínico
0	219	0.6010	0.7582	0.7667	0.0086
1	219	0.6076	0.7116	0.7116	0.0000
2	220	0.6160	0.6770	0.7117	0.0346
3	220	0.5789	0.7151	0.7234	0.0083
4	219	0.5969	0.6760	0.7081	0.0322

AUC media: promedio de las cinco AUC. AUC OOF agrupada: ordenación de todas las pacientes juntas. Las dos medidas pueden diferir porque los modelos de los folds producen distribuciones diferentes.

Discriminación y consistencia



Predicciones de pacientes fuera del aprendizaje de cada fold. Las etiquetas sí participan en la elección de checkpoint y candidato; los gráficos no representan una prueba independiente.




Comparación con el modelo clínico

Cambio AUC OOF +0.0175; IC95% descriptivo [+0.0059, +0.0292]. El comparador clínico usa las mismas cuatro variables, pacientes y particiones, sin CNN.

Intervalos percentiles de 4000 bootstrap pareados por paciente, estratificados por fold y clase. Condicionados a las predicciones elegidas; no incluyen toda la variabilidad de entrenar, ni corrigen la selección adaptativa.

Dinámica del aprendizaje



Total: 273 épocas físicas; 48.3 minutos acumulados de las épocas. En 5 de 20 runs se conserva la época 0. De los diez modelos elegidos, 3 mantienen todos los coeficientes visuales finales a cero.

Un peso visual distinto de cero confirma uso de la representación, pero no demuestra una mejora independiente debida a la imagen. Para valorar esa aportación se debe comparar con el modelo solo clínico y confirmar en una evaluación externa.

La optimización conjunta también reajusta la rama clínica con BCE por corte. Sin una ablación equiparada, la ganancia del pipeline no puede atribuirse exclusivamente a la imagen.

Bandas: rango intercuartílico. Las curvas tardías tienen menos runs por parada temprana. Loss train con aumentos/dropout y loss validación en evaluación; las revisiones AUC train usan modo evaluación.


Diagnóstico

Mejor época de los runs: mediana 1.5, mínimo 0 y máximo 9. El checkpoint elegido refleja el máximo AUC observado, no necesariamente la última época. La tabla completa de veinte ejecuciones está en el informe Markdown y runs.csv.

Última revisión, BCE normal: mediana AUC train 0.821, validación 0.677, brecha pareada mediana 0.147.

Última revisión, BCE ponderada: mediana AUC train 0.811, validación 0.686, brecha pareada mediana 0.132.

Probabilidades y cohortes



Platt por cross-fitting: Brier 0.1794; con umbral fijo 0,5, F1 0.3459, sensibilidad 0.2422 y especificidad 0.9342. Cada calibrador se ajusta con los otros cuatro folds; persiste el sesgo de selección del modelo base.

Modelo	Brier	F1	Sensibilidad	Especificidad
Multimodal crudo	0.2109	0.5530	0.7050	0.6490
Multimodal calibrado	0.1794	0.3459	0.2422	0.9342
Clínico calibrado	0.1846	0.2810	0.1863	0.9419

La inicialización clínica usa balanceo de clases. Se calibran ambos comparadores para revisar probabilidades y decisiones con umbral fijo 0,5.

El manifiesto usa umbral Youden 0.354333, obtenido sobre todo OOF junto con Platt. Sus métricas son aparentes, no una prueba independiente. Brier resume calibración y discriminación; no es una medida exclusiva de calibración.

AUC OOF por cohorte

Cohorte	N	pCR	CNN	Clínico	Multimodal
duke	209	44	0.5387	0.7431	0.7716
spy1	104	26	0.6016	0.7830	0.7618
spy2	784	252	0.5951	0.6927	0.7074

Cohortes presentes en desarrollo. Este análisis no deja una cohorte completa fuera del aprendizaje y no acredita generalización entre centros.

Decisión y evidencia conservada

Cumple los tres requisitos cuantitativos definidos (AUC media, AUC agrupada y AP sobre prevalencia).

La selección de épocas y de combinación utiliza estas mismas pacientes de validación. La evaluación es interna y adaptativa: puede sobreestimar la mejora y requiere confirmación en pacientes nuevas.

Por indicación del usuario se asume que edad, volumen tumoral, HR y HER2 estarán disponibles en la prueba privada. Es un supuesto de trabajo, no una confirmación externa. El informe conserva el modelo histórico y no realiza evaluación nueva sobre test.

Bajo el supuesto de disponibilidad clínica, el multimodal es un candidato razonable para la prueba privada. Mejora modestamente al modelo solo clínico, que sigue siendo una referencia importante por su menor complejidad; la ganancia adicional necesita confirmación independiente.

La mejora frente a la CNN histórica y la mejora frente al modelo clínico responden a preguntas distintas. Una diferencia grande respecto a la CNN puede proceder principalmente de añadir información clínica. El entrenamiento conjunto solo se justifica como aportación adicional si supera de forma reproducible al comparador clínico.

La AUC 0,546 del test congelado pertenece exclusivamente a la CNN anterior. No se ha calculado el rendimiento del nuevo candidato sobre ese test ni sobre la prueba privada. El modelo histórico se conserva.

Reproducibilidad

Pasaron 19 pruebas y humo CUDA. Se verificaron veinte runs, 1097 pacientes OOF, 10945 cortes y hashes de diez checkpoints. Se conservaron 88 archivos protegidos. Los runs cargaron 0 imágenes de test.

Código: 0b10e7c4f745716985a0950ea81e0b63e0fafb2d

Manifiesto: resultados/04_entrenamiento/multimodal_clinico_20261007/comparacion/modelo_desarrollo.json

SHA-256: 534521e1aa41fadc4276949071c8c3bd6839d297659d6ef06e7ca5dca699f62a

Regenerar: .venv/bin/python -B 06_informe_multimodal.py. Evidencia numérica y figuras: resultados/06_informe_multimodal_20261007/. Pesos y log: resultados/04_entrenamiento/multimodal_clinico_20261007/.

Fuentes metodológicas

Validación cruzada y preprocesado dentro de train

https://scikit-learn.org/stable/modules/cross_validation.html

Sesgo de selección y validación anidada

https://scikit-learn.org/stable/auto_examples/model_selection/plot_nested_cross_validation_iris.html

Calibración de probabilidades

<https://scikit-learn.org/stable/modules/calibration.html>